

TRABAJO FINAL: CASO VIKINGS FISH CO.

ABSTRACTO

El Riesgo Operativo (Op Risk) es “el riesgo de pérdidas resultantes de procesos internos inadecuados o fallidos, personas y sistemas, y eventos externos”. Aunque no es nuevo, su control y gestión han adquirido una importancia creciente para que las instituciones financieras sigan siendo competitivas. Además, el hecho de que el Nuevo Acuerdo de Capitales de Basilea lo haya incluido entre sus requerimientos de capital, aportando una definición del mismo para el sector, ha propiciado que las entidades empiecen a desarrollar un modelo completo de gestión que les permita su identificación, valoración, seguimiento, control y mitigación.

El objetivo de este trabajo es realizar un análisis de las pérdidas históricas de la empresa Vikings Fish Co. para desarrollar modelos que faciliten el control y previsión ante el riesgo y así tomen las medidas a tiempo. Se utilizarán herramientas de inferencia estadística (como el Análisis y Estimación de la Frecuencia de eventos de Pérdidas y Severidad, Teoría de Valores Extremos, Distribución de Pérdidas Agregadas y Modelo Value at Risk) y librerías R.

INTRODUCCIÓN

En el presente informe, se realiza el estudio y formulación de herramientas para la gestión del riesgo operativo de la línea de negocio “cultivo de salmón”, que es el negocio más rentable de la empresa Vikings Co. Vikings Fish Co. es una empresa danesa que se dedica al cultivo de distintas especies de pescado en tierra, con piscifactorías en 12 países. Para el análisis del riesgo operativo, la empresa entregó las pérdidas incurridas durante 11 años.

I. ANÁLISIS EXPLORATORIO DE DATOS

El Análisis de Riesgo Operativo comprende el estudio de dos componentes Severidad (los importes de las pérdidas) y frecuencia de los eventos (o siniestros). Para el caso de Viking Fish Co. Se tiene un dataset de las pérdidas diarias de una línea de negocio en el periodo 03/01/1980 al 31/12/1990. En cuanto a la Frecuencia de Siniestros, fue necesario convertir las ocurrencias de las pérdidas en una serie temporal diaria, donde se incluyeron los días que no se tuvieron pérdida, con la finalidad de ajustar una distribución adecuadamente.

1.1. ESTADÍSTICOS

Los valores estadísticos de las variables son los siguientes:

	Min	Mediana	Media	Moda	SD	Max
Pérdidas	1	1.8	3.4	1	8.5	263.3
Frecuencia	0	0.0	0.5	0	0.8	5.0

Las pérdidas tienen valores medio, mediana y modas diferentes por lo que aparentemente no se distribuye de forma asimétrica. También se observa que la moda se encuentra en el valor mínimo 1, parece que tiene una cola pesada a la derecha. De forma similar, la frecuencia de los siniestros tiene la moda en el valor mínimo 0, por lo que también se trata de una distribución asimétrica con cola a la derecha.

1.2. CUANTILES

1.2.1. Variable “Pérdidas”

Los cuartiles muestran que entre el 80% al 100% hay una diferencia mayor a 200, lo que muestra que tiene una cola a la derecha.

0%	20%	40%	60%	80%	100%	
1.000000	1.253616	1.576994	2.062706	3.478227	263.250366	
5%	95%					
1.057787	9.972647					
90%	91%	92%	93%	94%	95%	96%
5.541526	5.789766	6.307607	7.122405	8.086388	9.972647	11.744787
97%	98%	99%	100%			
14.293330	18.604151	26.042526	263.250366			

1.2.2. Variable “Frecuencia de Eventos”

Se comprueba los resultados de los estadísticos, porque entre los cuartiles del 99% a 100% hay una diferencia de 2, lo que muestra una cola a lado derecho.

0%	20%	40%	60%	80%	100%					
0	0	0	1	1	5					
5%	95%									
0	2									
90%	91%	92%	93%	94%	95%	96%	97%	98%	99%	100%
2	2	2	2	2	2	2	2	3	3	5

1.3. REPRESENTACION GRAFICA

La representación gráfica permite ver con más claridad el comportamiento de los datos.

1.3.1. Variable “Pérdidas”

Tiene una densidad asimétrica, con valor alto en el extremo izquierdo, y presenta una cola alargada a la derecha (Ver Apéndice B Fig.1). Solo cuenta con valores positivos. El diagrama de cajas (Ver Apéndice B Fig.3). muestra los valores de la cola como valores outliers. La serie temporal (Ver Apéndice B Fig.3). se presenta como estacionaria en media, no estacionaria en varianza y no estacional.

1.3.2. Variable “Frecuencia de Eventos”

El histograma (Ver Apéndice B Fig.4) muestra gran incidencia en el valor mínimo que es 0, asimetría con cola a la derecha. La serie temporal (Ver Apéndice B Fig.5) de la frecuencia muestra un comportamiento no estacionario en media ni varianza, tiene mucha variación entre los periodos semanales. No es estacional. El diagrama de cajas muestra que la moda es igual al valor mínimo (0) e identifica tres casos como outliers (Ver Apéndice B Fig.6).

1.4. SIMETRÍA

El coeficiente de Skewness prueba si se tiene simetría en la distribución de los datos, y si es igual a 0 significa que los datos son totalmente simétricos.

1.4.1. Variable “Pérdidas”

En el caso de esta variable se obtiene un 18.75, lo cual significa que no es una distribución Simétrica, por lo que una distribución normal no es apropiada para las pérdidas. Al ser mayor a 0, se puede estimar que los valores se tienden a reunir más en la parte izquierda que en la derecha de la media (valor de la moda en la izquierda).

[1] 18.74983

1.4.2. Variable “Frecuencia de Eventos”

El coeficiente de la frecuencia de eventos (1.43) se comprueba que es asimétrica y que tiene mayor densidad a la izquierda que a la derecha (cola a la derecha).

[1] 1.434283

1.5. KURTOSIS

Esta medida determina el grado de concentración que presentan los valores en la región central de la distribución. Por medio del Coeficiente de Curtosis, podemos identificar si existe una gran concentración de valores (Leptocúrtica), una concentración normal (Mesocúrtica) ó una baja concentración (Platicúrtica).

1.5.1. Variable “Pérdidas”

El coeficiente de kurtosis de las pérdidas es 485.6, lo que significa que es una distribución leptokurtica, es decir que es más plana que una distribución normal.

[1] 485.6461

1.5.2. Variable “Frecuencia de Eventos”

Al ser mayor a 3, el coeficiente de kurtosis de la frecuencia de eventos, muestra que se trata de una distribución leptokurtica, similar al de pérdidas, es más aplanada que una distribución normal.

[1] 5.122831

II. SELECCIÓN DEL MODELO: INFERENCIA PARAMÉTRICA

La estadística paramétrica, como parte de la inferencia estadística, trata de estimar determinados parámetros de una población de datos. La estimación, como casi siempre en estadística, se realiza sobre una muestra estadística. Mediante las técnicas de estadística paramétrica, se puede desarrollar modelos paramétricos basados en las distribuciones estadísticas para explicar el comportamiento de los datos de Vikings Fish Co.

2.1. VARIABLE “Pérdidas” (Severidad)

Esta variable contiene datos continuos y es asimétrica (como se comprobó con el coeficiente de simetría). Además, se conoce que el valor más frecuente es 1 (Valor Mínimo). Entre las distribuciones que se ajustan estas características se tienen: Exponencial, Log-Normal, Gamma, Weibull

Estas distribuciones fueron sometidas a ajustes según el método de “Máxima Verosimilitud”, método de “Máxima Bondad de Ajuste”, mediante “Medidas de Adecuación Kernel” y método de “Momentos”.

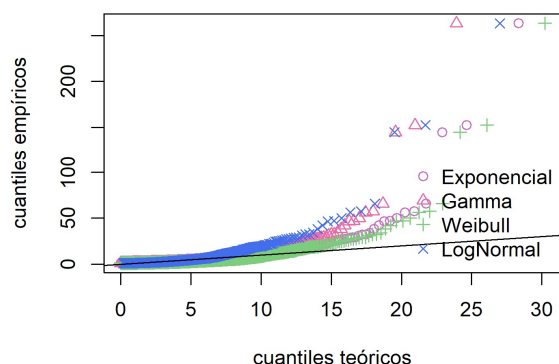
2.1.1. METODO DE MAXIMA VEROSIMILITUD(MLE)

Mediante este método, las funciones de distribución que mejor se ajustaron a los datos con menor error fueron Gamma y Log-normal (El detalle de los ajustes se realizan en el archivo Rmd, adjunto en el Apéndice C). A continuación, se muestra la tabla comparativa de los resultados de la prueba de contraste de bondad:

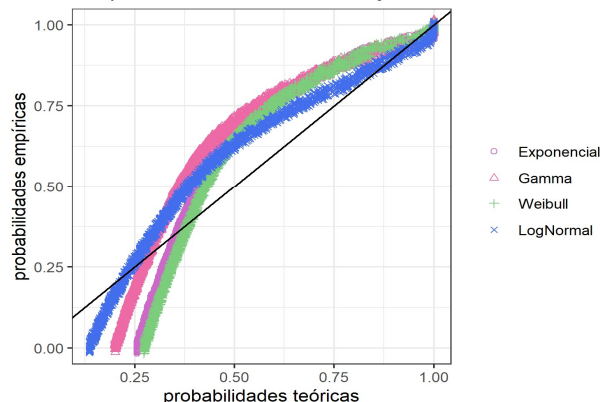
	Exponencial (0.295)	Gamma (1.298, 0.383)	Weibull (0.959, 3.292)	LogNormal (0.787, 0.717)
AIC	9620.793	9538.191	9611.243	8119.795
BIC	9626.474	9549.554	9622.605	8131.157

Los gráficos QQ-Plot y PP-Plot muestran una comparativa más detallada del comportamiento de estas funciones con respecto a los datos. Se observa que la distribución Log-Normal tiene un ajuste más constante que las otras como se muestra en el PP-Plot.

QQ-plot sobre Distribuciones Ajustadas a la Severic



PP-plot sobre Distribuciones Ajustadas a la Severidad



También se aplicaron a las funciones medidas de adecuacion, para contemplar si es que metodos no parametricos explican mejor los casos de perdidas, pero finalizado el analisis no se mostraron mejoras significativas que los resultados de las funciones gamma y log-normal (detalle en Apéndice C: Archivo Rmd).

2.1.2. METODO DE MOMENTOS(MME)

Este método ajusto las funciones Exponencial, Gamma, Weibull y Log-Normal, las mejores funciones fueron la Exponencial y Log Normal, como muestra la siguiente tabla (el detalle del código se encuentra en el Apéndice C). Los resultados de la prueba de Contraste de Bondad son los siguientes:

	Exponencial (0.295)	Gamma (0.158, 0.047)	Weibull (0.461, 1.44)	LogNormal (0.225, 1.41)
AIC	9620.793	13335.98	11559.64	9791.887
BIC	9626.474	13347.35	11571.00	9803.249

Sin embargo, los resultados de las funciones de Máxima Verosimilitud obtuvieron mejores resultados, por lo que es recomendable utilizar la función Log-Normal para explicar los datos de Severidad. Esta conclusión se considera en la generación de la función de distribución de Pérdidas Agregadas.

2.2. VARIABLE “Frecuencia de Eventos”

Esta variable contiene datos discretos y es asimétrica (como se comprobó con el coeficiente de simetría). Además, se conoce que el valor más frecuente es 0 (Valor Mínimo). Entre las distribuciones que se ajustan estas características se tienen: Poisson, Binomial Negativa, Uniforme Discreta, Geométrica.

Estas distribuciones son sometidas a ajustes según el método de “Máxima Verosimilitud”, método de “Máxima Bondad de Ajuste”, mediante “Medidas de Adecuación Kernel” y método de “Momentos”.

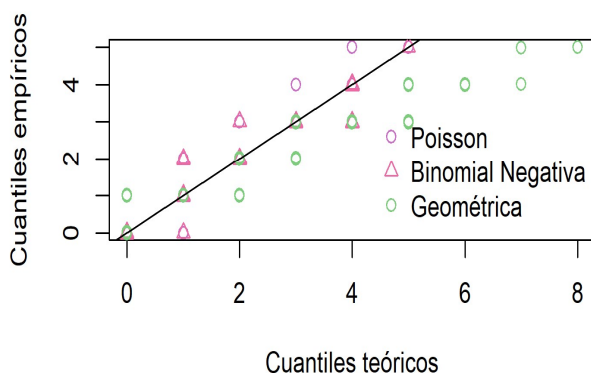
2.2.1. METODO DE MAXIMA VEROSIMILITUD(MLE)

Mediante este método, la función de distribución de Poisson presento un mejor ajuste y con menor error (detalle de los ajustes se realizan en el archivo Rmd, adjunto en el Apéndice C). A continuación, se muestra la tabla comparativa de los resultados de la prueba de contraste de bondad:

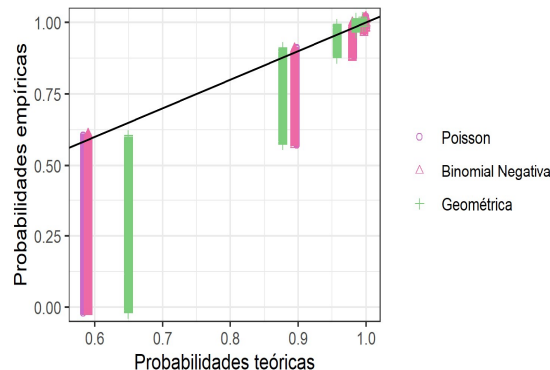
	Poisson (0.540)	Binomial Negativa (11.916,0.540)	Geométrica (0.650)
AIC	7819.697	7817.864	8011.971
BIC	7825.995	7830.460	8018.269

El grafico CDF muestra una comparación grafica de las distribuciones con respecto a los datos de la muestra. Se observa que la función Poisson es la más adecuada (Ver Fig.7). Los gráficos qq-Plot y PP-Plot muestran también que la función Poisson es la que mejor se ajusta:

QQ-plot sobre Distribuciones Ajustadas a la Frecuer



PP-plot sobre distribuciones ajustadas a la Frecuencia



De igual manera a la variable Severidad, se aplicaron a las funciones medidas de adecuación, para contemplar si es que métodos no paramétricos explican mejor los casos de perdidas, pero finalizado el análisis no se mostraron mejoras significativas que los resultados a la función Poisson (detalle en Apéndice C: Archivo Rmd).

2.2.2. METODO DE MOMENTOS(MME)

La mejor distribución mediante este método es la Poisson, que tiene menor error y resulta tener el mismo valor de lambda que el método MME (el detalle del código se encuentra en el Apéndice C). Los resultados de la prueba de Contraste de Bondad son los siguientes:

	Poisson (0.540)	Binomial Negativa (12.091,0.540)	Geométrica (0.650)
AIC	7819.697	7817.865	8011.971
BIC	7825.995	7830.461	8018.269

La mejor distribución es la Poisson(0.540) que demuestra un buen ajuste y menor rango de error.

III. ANÁLISIS DE LOS VALORES EXTREMOS

Existe, bajo Basilea II, un conjunto de métodos cuantitativos para el cálculo de la carga de capital por riesgo operativo, pero no hay consenso sobre los mejores métodos a emplear. Una técnica que se ha vuelto potencialmente atractiva es la Teoría de Valor Extremo (EVT), la cual no parece ser directamente aplicable a satisfacer las estrictas normas establecidas por Basilea; esto se debe a que simplemente no hay suficientes datos. Los métodos estándar de modelización matemática del riesgo utilizan el lenguaje de teoría de la

probabilidad. Dichos riesgos son variables aleatorias que pueden ser consideradas individualmente o vistas como parte de un proceso estocástico. Los potenciales valores de una situación de riesgo tienen una distribución de probabilidad para las pérdidas derivadas de los riesgos, pero hay un tipo de información que está en la distribución, llamada eventos extremos, los cuales se producen cuando un riesgo toma valores en la cola derecha de la distribución de pérdidas. En EVT hay dos tipos de enfoques que generalmente se aplican:

3.1. DISTRIBUCIÓN GENERALIZADA DE BLOCK MÁXIMA

Se trata del método más tradicional, consiste en agrupar las observaciones por bloques y en estos encontrar el máximo. Su desventaja radica en la incorrecta selección del tamaño de bloques (semanales, mensuales, etc.).

Se deben excluir los eventos de crisis financiera de Dinamarca, que afectan el comportamiento de las pérdidas, en este caso el periodo del dataset es enero del 1980 a diciembre del 1990. Durante ese periodo, Dinamarca no tenía una economía sólida como la tiene ahora pero no presenta eventos excepcionales.

Se aplicó el código del ejercicio 5.21 del libro "The Quantitative Risk Management Guide Book" de Marius Hofert, donde se realizaron ajustes dado que se aplicaba directamente a las pérdidas no al precio de las acciones. El día en donde se produjo la mayor pérdida fue el 15/07/1980 del primer bloque. Se estimaron el ratio de variación del día anterior con respecto al mes anterior y al 120 días antes:

	Periodo	% Var
2 días previos	13/09/1980 - 14/07/1980	-60.2%
Vs. Mes Anterior	14/06/1980 - 14/07/1980	-40.9%
Vs. Trimestre Pasado	14/03/1980 - 14/07/1980	-0.09%

En la Figura 8 (en el apéndice B), se muestran las variaciones mensuales. Se utiliza la función `fit_GEV_MLE` para modelar estos casos extremos de manera semanal, esto es debido a que anualmente no es conveniente por las variaciones entre los periodos. La distribución resultante obtiene los parámetros de shape, loc y scale:

```
[1]Shape: -0.1917433
```

```
[1]Loc: 0.564446
```

```
[1]Scale: 0.8165074
```

Standard Errors:


```
      shape      loc      scale
0.2019885 0.1838410 0.1389606
```

Utilizando la distribución generada, se puede estimar la probabilidad del excedente dentro de un año y es del 3.53%, muy poco probable. Lo cual es real por que Dinamarca mejoro su economía a partir de esos periodos.

```
[1] 0.03532686
```

3.2. ANÁLISIS PEAKS-OVER-THRESHOLD (UMBRAL)

Es el método más utilizado, porque puede ser utilizado para modelizar muestras de cualquier tamaño. Consiste en identificar las observaciones que exceden determinado umbral y se les asigna una probabilidad de ocurrencia. Al igual que el método block-máxima, éste lleva a un error en la mala selección del umbral. Se seleccionó el umbral 25 (cercano al penúltimo cuartil 99%). Se identificaron 24 casos de valores extremos los cuales son graficados a continuación: el gráfico de Excesos vs Probabilidades, muestra que la pendiente es negativa y que la cola se aleja de los datos reales. Se muestra un comportamiento similar en el gráfico de probabilidades de no exceder.



3.2.1. Distribución Generalizada de Pareto (GPD)

Una técnica inspirada en el método del umbral es la distribución de Pareto generalizada. Viene caracterizada por los parámetros de escala $\bar{\delta}$ y de forma $-\infty < \xi < +\infty$. Según las condiciones anteriores, si los máximos por

bloques siguen una distribución G, entonces la distribución de los excesos del umbral se encuentran dentro de la familia de distribuciones de Pareto Generalizada. Mediante la función `nlk.gp`, se obtiene la función de distribución generalizada ajustada a los datos:

```
$estimate
```

```
[1] 10.4022836 0.8228792
```

Los graficos QQ-Plot y PP-Plot de la distribución generalizada de Pareto (Ver Fig. 9 – Apéndice B) muestran que esta función se ajusta de mejor manera que el método del umbral anterior.

IV. COMUNICACIÓN DE RESULTADOS: DISTRIBUCIÓN DE PÉRDIDAS AGREGADAS

Finalmente, con las conclusiones del análisis de cada variable, se puede desarrollar la función de distribución de pérdidas agregadas. La función de Severidad es una distribución de Log Normal (0.7869501,0.7165545) y la frecuencia se expresa en una distribución Poisson(0.5395916). Existen 3 funciones de aproximación: Simulación, Normal y Normal-Power. El grafico comparativo (Ver Fig. 10 en Apéndice B) muestra que la función generada por simulación es la que mejor se ajusta a la función exacta. Si bien la aproximación normal incluye las pérdidas menores, distorsiona los valores mayores (cola derecha).

V. Conclusiones

Las empresas enfrentan pérdidas operativas en su día a día. Algunos ejemplos son las pérdidas resultantes de errores de los empleados, fraude interno o externo, fallas en los equipos, problemas ante desastres naturales y vandalismo. Este riesgo operativo afecta la eficiencia operacional en todas las unidades de negocios. En el caso de Vikings Fish Co. solo se cuenta con la información de una línea de negocio, pero es importante tener como paso futuro la información histórica de las otras líneas para modelizar el riesgo e implementar los modelos en el sistema de control de riesgo de la empresa.

Quisiera incluir en este análisis, como punto relevante, que la información brindada es de los años 1980 a 1990, de una empresa danesa. Dinamarca ahora se presenta como un país con más solidez económica que en ese periodo, es por ello que no puedo concluir que el modelo presentado en el informe sea el final. Es adecuado ajustarlo con nuevos datos (más actuales) y añadir en el documento final un plan de monitoreo y ajustes para que este modelo sea adecuado ante las nuevas cocurrencias y sirva como herramienta óptima para el área de riesgos.

VI. Bibliografía

- CHERNOBAI, Anna S.; RACHEV, Svetlozar T.; FABOZZI, Frank J. Operational risk: a guide to Basel II capital requirements, models, and analysis. John Wiley & Sons, 2008.
- ZALEWSKA, Anna. Operational Risk: Guide OpVar, 2010, Junio. Código R: <https://github.com/barryrowlingson/opVaR/blob/master/R/key.sum.R>
- HOFERT, Marius; FREY, Rüdiger. The Quantitative Risk Management Exercise Book. Código R: https://github.com/qrm/tutorial/qrm/blob/master/code/The_QRM_Exercise_Book/08_Aggregate_Risk.R

APÉNDICE A: MEDICIÓN DEL RIESGO EXTREMO “VALUE AT RISK(VaR)”

- **VaR (Valor en Riesgo):** En el contexto del riesgo operativo, VaR es, hablando informalmente, la cantidad total de capital de un periodo que sería suficiente para cubrir todas las pérdidas inesperadas con un alto nivel de confianza.

VaR es una poderosa herramienta estadística que ha ganado popularidad dentro de la comunidad financiera y se ha convertido en un punto de referencia para medir y pronosticar riesgos de mercado, crediticios, operativos y de otro tipo. Intuitivamente, VaR determina la peor pérdida posible que puede ocurrir con un nivel de confianza dado y para un período de tiempo determinado. $(1 - \alpha) * 100$ VaR se define como el percentil $(1 - \alpha)$ de la distribución de pérdidas en un horizonte de tiempo objetivo t . $1 - \alpha$ se llama nivel de confianza. Por ejemplo, un VaR de 95% de un año es la cantidad total de pérdida que puede ser superada por el total de todas las pérdidas potenciales que pueden ocurrir durante un período de un año, no más del 5% del tiempo. Se deben especificar tres parámetros antes de calcular VaR:

- Nivel de confianza (generalmente se toma entre 95% y 99%)
 - Horizonte de pronóstico
 - Moneda base
- **CVaR (Valor en Riesgo Condicional):** determina la cantidad de dinero que se espera perder si se produce un evento en la cola derecha de la distribución más allá del VaR. Formalmente, para un nivel de confianza dado $1 - \alpha$ y un horizonte de tiempo preespecificado Δt , CVaR se define como: $CVaR = E[S_{\Delta t} | S_{\Delta t} > VaR]$ La relevancia de CVaR como medida de riesgo apropiada se vuelve cada vez más importante cuando la elección del modelo correcto se vuelve dependiente de eventos extremos.

A continuación, utilice el código del ejercicio del cálculo de VaR y CVaR en Riesgo Operativo del libro “The Quantitative Risk Management Exercise Book” de Marius Hofert. Estas aproximaciones son teóricas y se basan en el nivel de confianza del 95%. Los números son pequeños por que se calculan a nivel diario:

1. Aproximación Normal

Mediante esta técnica se asume que la distribución de la pérdida total sigue el comportamiento de una distribución normal con la media $\bar{x} = \lambda_{poisson} * Exponential(\mu_{Log} + \frac{(\delta_{log})^2}{2})$ y varianza $Var(x) = \lambda_{poisson} * Exponential(2 * \mu_{Log} + \frac{(2 * \delta_{log})^2}{2})$. Se obtienen los siguientes resultados:

```
[1] "VaR 95%: 5.96747754535858"
[1] "CVaR 95%: 7.09420607865839"
```

2. Aproximación Gamma Trasladada

Este método se basa en que la Pérdida Total se distribuye en una gamma con los mismos parámetros. Se obtuvo los siguientes resultados:

```
[1] "VaR 95%: 6.94044490587174"
[1] "CVaR 95%: 10.3404460178629"
```

3. Recursión Panjer

El algoritmo de Panjer está basado en el cálculo de la distribución compuesta mediante convoluciones. Se utiliza el hecho de que la distribución de la suma de dos variables aleatorias continuas independientes puede ser calculada como una convolución. Se simula las diferentes distribuciones compuestas de forma recursiva y se obtiene una función compuesta donde se estima la cola para determinar el VaR y CVaR.

```
[1] "VaR 95%: 8"
[1] "CVaR 95%: 11.2769608453626"
```

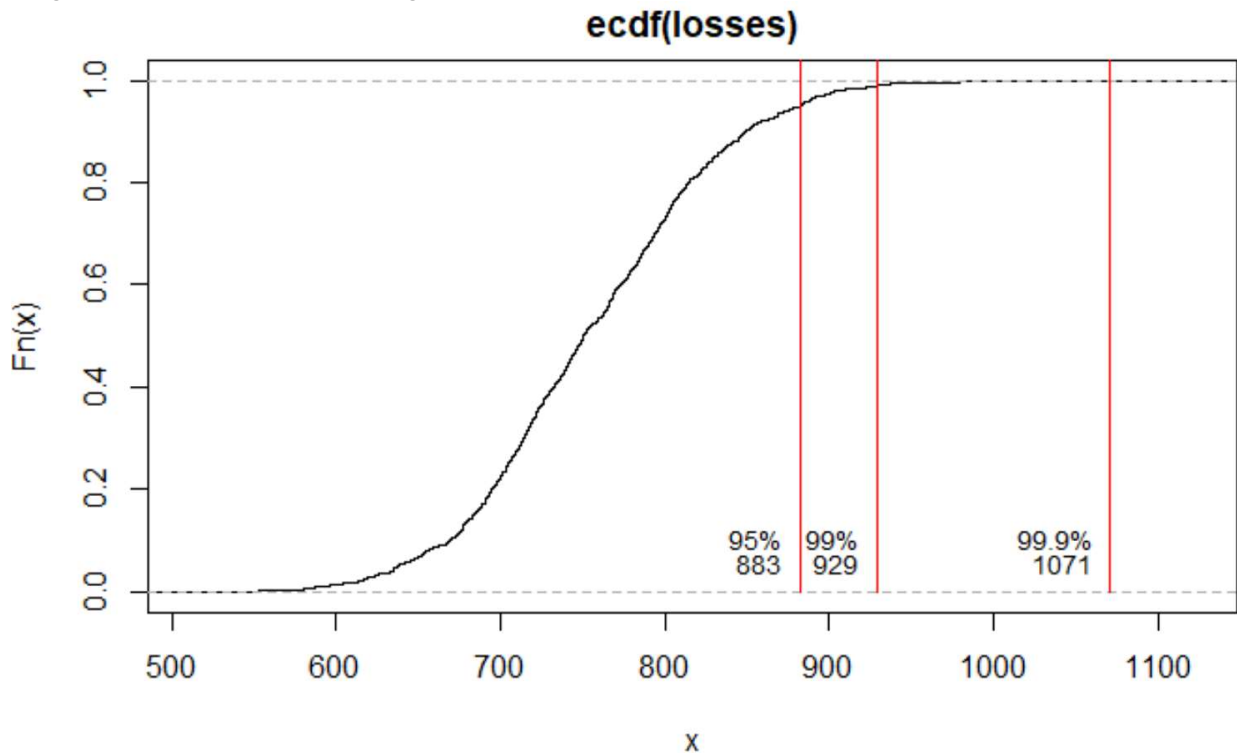
4. Transformada Rápida de Fourier

La Transformada rápida de Fourier es un algoritmo eficiente que permite calcular la transformada de Fourier discreta (DFT) y su inversa. La FFT es de gran importancia en una amplia variedad de aplicaciones, desde el tratamiento digital de señales y filtrado digital en general a la resolución de ecuaciones en derivadas parciales o los algoritmos de multiplicación rápida de grandes enteros.

```
[1] "VaR 95%: 8"
[1] "VaR 95%: 11.2788893187088"
```

También, agrego a continuación un código para calcular el VaR de forma exacta. La función `mc` de la librería “`opVar`” propuesta por Anna Zalewzka. Los pasos que se realizan son:

- Se genera una secuencia de n números aleatorios por la distribución rpoisson. En este caso como los datos están en días, se estiman $365 * 1000$ números. Siendo 1000 iteraciones y 365 días los que tiene el año.
 - Luego se genera la pérdida por cada número de eventos generados en el paso anterior.
 - Se crea una matriz de perdidas con dimensiones con $365 * 1000$ filas y las columnas se basa en el número de incidencias generadas por la rpois en la iteración i .
 - Se suman las pérdidas de las $365 * 1000$ iteraciones (suma de filas).
 - Se grafican y se estima el valor del cuantil.
- La grafica resultante es la siguiente:



APÉNDICE B: GRAFICOS

Fig. 1. Histograma de Pérdidas




Fig. 2. Serie Temporal de Pérdidas




Fig. 3. Boxplot de Perdidas




Fig. 4. Histograma de Frecuencia




Fig. 5. Serie Temporal de Frecuencia




Fig. 6. Boxplot de Frecuencia




Fig. 7. CDF Distribución de Frecuencia

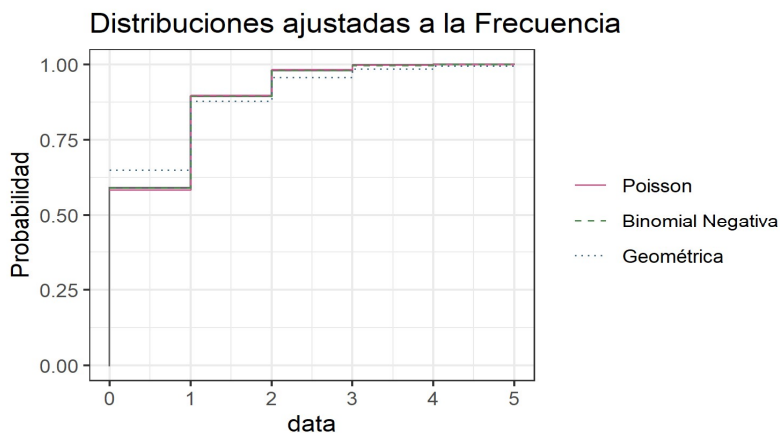


Fig. 8. Variaciones de las Perdidas (Block Maxima)

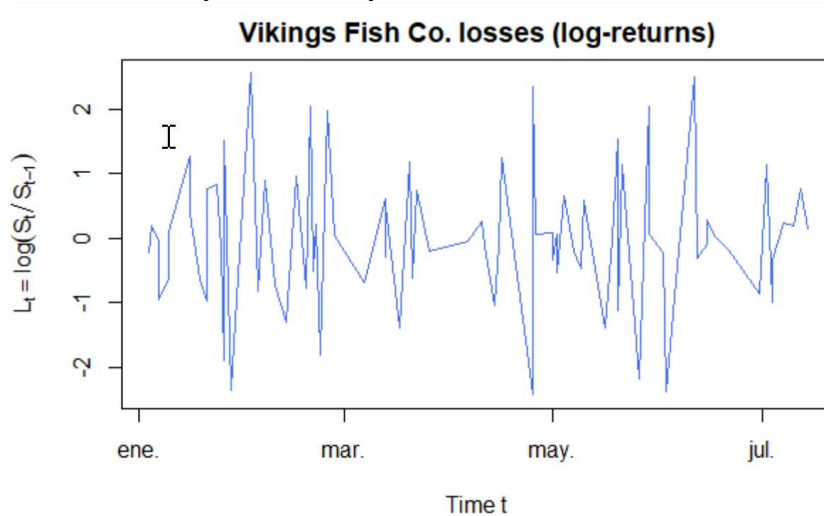


Fig. 9. Graficos QQ-Plot y PP-Plot Distribucion Generalizada de Pareto:

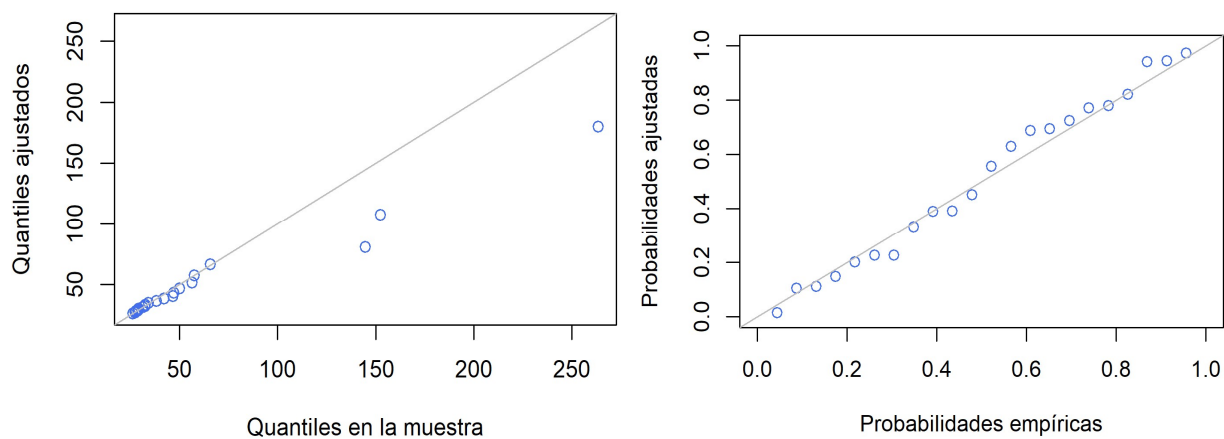



Fig. 10. Distribución de Perdidas Agregadas

Distribución Agregada de Pérdidas

APÉNDICE C: Archivo Rmd.



Practica Final
GRO.Rmd